

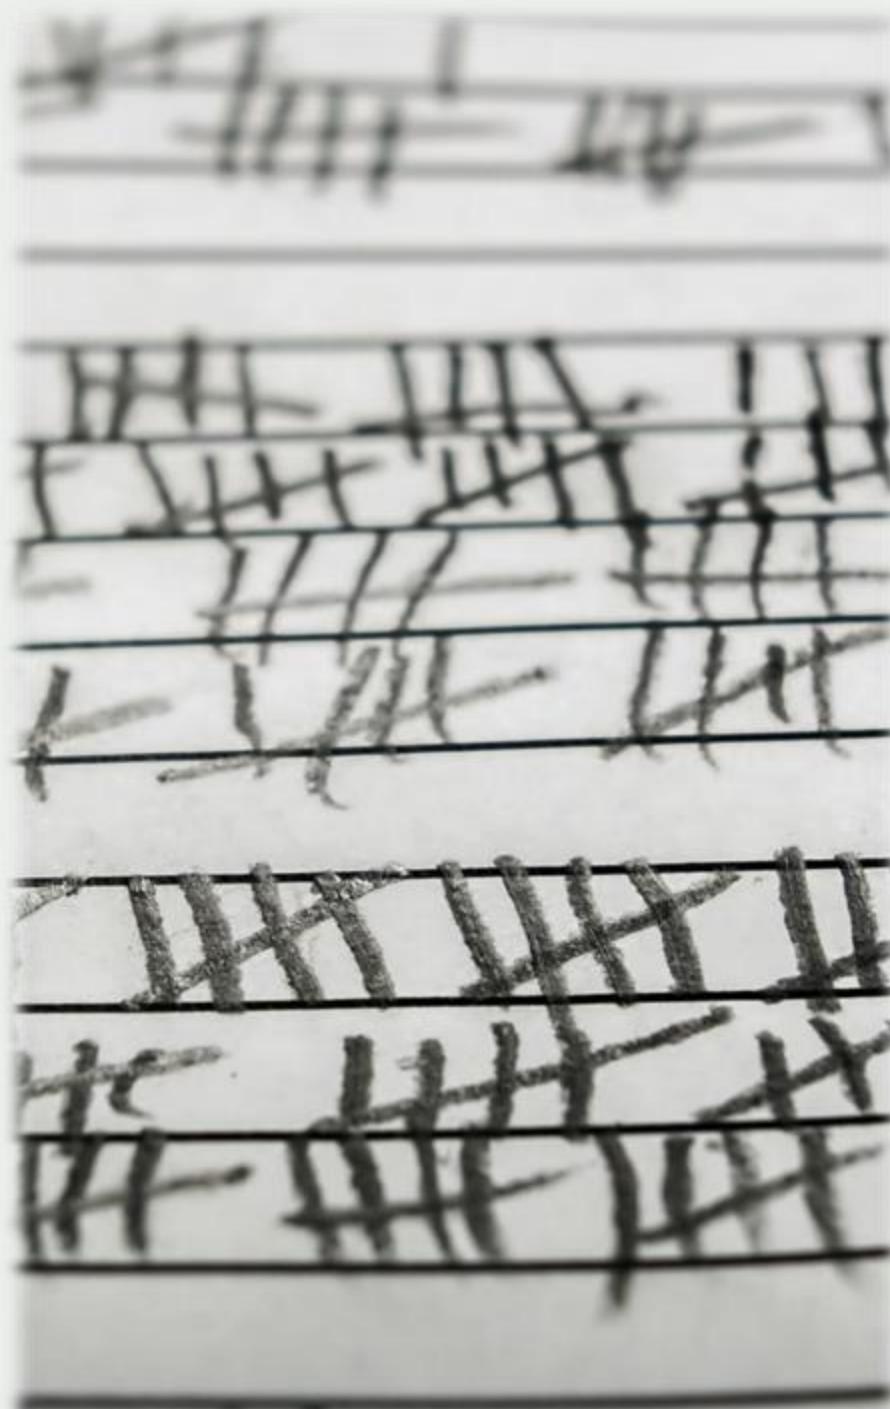
Machine learning nello Screening della Disgrafia

TECNICHE INNOVATIVE PER DIAGNOSTICARE
E ANALIZZARE DISAGI SCRITTURALI

Aseed Salma - 13030A Leggio Patrizia - 12158A

Introduzione alla Disgrafia

- COS'È
- DIAGNOSI
- VANTAGGI DELL'USO DELL'AI NELLO SCREENING



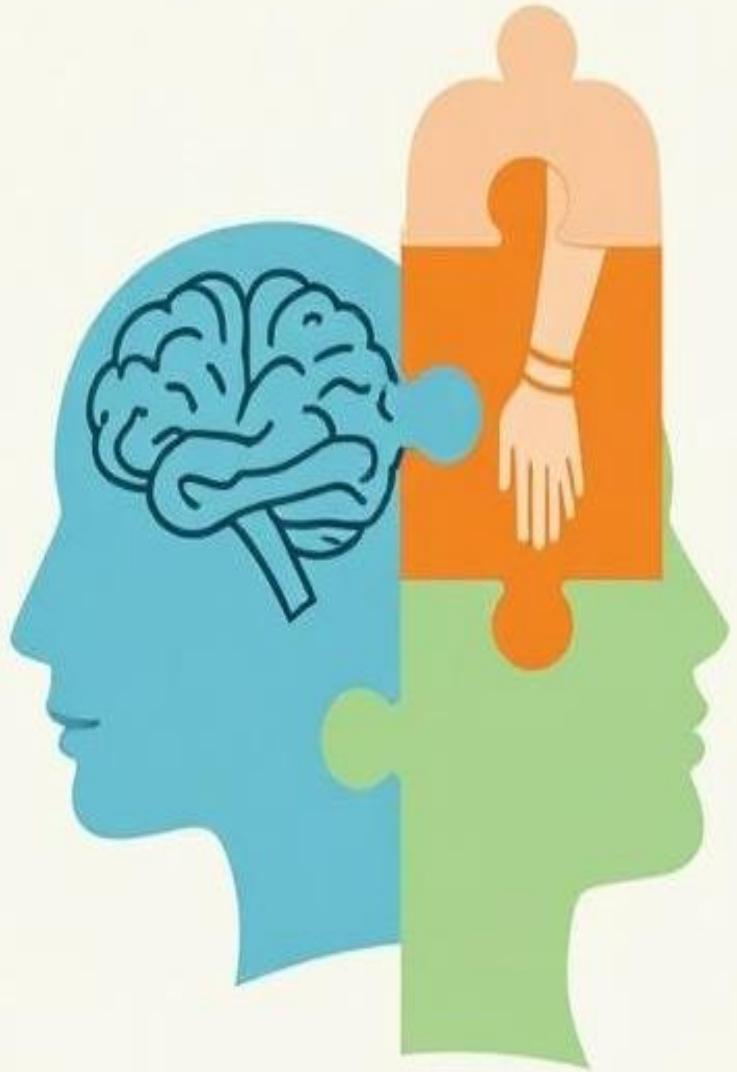
Cos'è la disgrafia

La disgrafia è un disturbo specifico dell'apprendimento che riguarda la scrittura manuale e la grafia, non l'intelligenza.

Include:

- lettere dalla forma irregolare,
- dimensioni incoerenti,
- spaziatura non uniforme,
- lentezza nello scrivere
- allineamento scorretto.

La disgrafia è legata a difficoltà nei processi motori fini, visuo-spatiali e nella pianificazione del gesto grafico.



Diagnosi

La diagnosi avviene ad opera di un'équipe multidisciplinare formata da neuropsichiatra infantile, psicologo e logopedista che devono prima di tutto escludere deficit intellettivi, disturbi neurologici o problemi attentivi importanti.

Obiettivo dello screening

Distinguere tra grafia immatura e disturbo permette di decidere se è necessario un approfondimento diagnostico specialistico.

Nello screening vengono analizzati:

- ✓ Forma delle lettere
- ✓ Dimensione e spaziatura
- ✓ Allineamento sul rigo
- ✓ Pressione sul foglio
- ✓ Postura e impugnatura

Vantaggi del Machine Learning nello screening

Obiettività

Riduce la soggettività dell'osservazione manuale

Velocità

Analizza molti campioni in breve tempo

Quantificazione

Misura parametri motori e grafici complessi

Prevenzione precoce

Individua segnali di rischio prima che si consolidino

Machine Learning nello Screening della Disgrafia

- MACHINE LEARNING NELLO SCREENING
- TECNICHE ML NELLO SCREENING AUTOMATICO



Machine Learning nello screening

Modelli di ML possono confrontare la scrittura di un bambino con dati di riferimento di bambini con e senza disgrafia producendo un indice di rischio per valutare chi necessita di valutazione specialistica.

LIMITI

- ✓ Non sostituisce la valutazione clinica completa
- ✓ Richiede hardware digitale (tablet, penna sensoriale) o scansione
- ✓ Alcuni modelli devono essere tarati per età, lingua e sistema di scrittura.

Tecniche ML nello screening automatico

Classificatore tradizionale (Support Vector Machine – SVM)

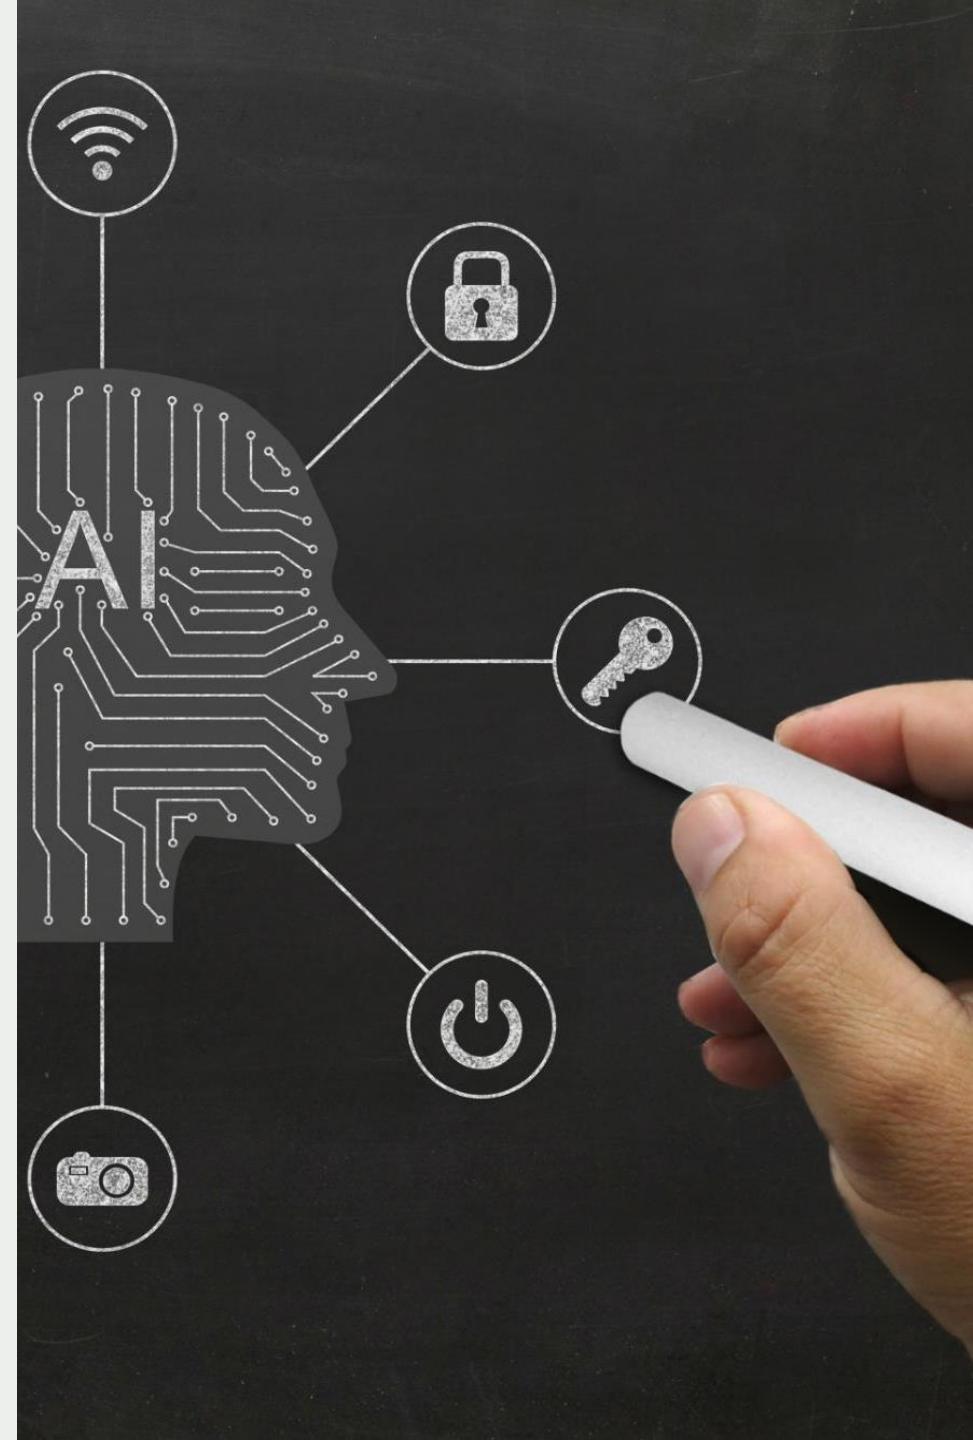
- ✓ Buona separazione binaria
- ✓ Funziona bene anche con dataset di dimensioni moderate
- ✓ E' robusto nella classificazione di pattern complessi

Rete neurale convoluzionale (CNN)

- ✓ Estrae automaticamente feature visive (forme delle lettere, distorsioni, spaziatura)
- ✓ Riconosce pattern invisibili ad occhio umano

Feature extraction + ML classici

- ✓ Estrazione di feature numeriche (es. Distanza tra lettere, dimensione, inclinazione)
- ✓ Classificatori come AdaBoost, XGBoost o SVM



ANALISI CODICE

- DATASET
- LE FASI DELL'APPRENDIMENTO
- LIMITI DEL CODICE

Dataset utilizzati

Il codice non si affida a un'unica fonte dati, ma combina due dataset distinti (ImageNet e Mendeley Data) per superare la scarsità di campioni clinici.

ResNet18

Rete convoluzionale per immagini statiche. Fornisce alla rete neurale la capacità visiva di base (riconoscimento di bordi, curve, texture) appresa su 1.2 milioni di immagini generiche (ImageNet). Permette al modello di convergere velocemente (in meno di 10 epoch) anche se il tuo dataset specifico è piccolo.

Potential Dysgraphia Handwriting Dataset (Mendeley Data) - licenza CC BY 4.0

È uno dei pochi dataset specifici per disgrafia raccolti da bambini delle scuole primarie. Contiene immagini di scrittura classificata in base al rischio di disgrafia (potenziale o basso potenziale), valutata da esperti. Contiene 249 campioni di cui 114 valutati come disgrafici. Serve per il Fine-Tuning. Il modello adatta la sua conoscenza generale per distinguere specificamente i tratti tremolanti o irregolari della disgrafia.

Viene diviso in Training Set (80%) e Test Set (20%) tramite la funzione `train_test_split`.

Le fasi dell'apprendimento

Le immagini vengono convertite in scala di grigi e ridimensionate a 128x128 pixel

Poiché ResNet nasce per immagini a colori (3 canali), il primo strato convoluzionale viene modificato manualmente per accettare 1 solo canale (grigio)

Per evitare che il modello impari a memoria le poche immagini (overfitting), ogni immagine di training viene trasformata dinamicamente ad ogni epoca applicando una rotazione, una deformazione e una sfuocatura

Validazione Incrociata: Il codice esegue un K-Fold (5 giri) per verificare la stabilità del modello prima dell'addestramento finale.

Ottimizzazione
Dinamica: Durante il training finale (30 epoche), viene utilizzato uno Scheduler. Se la "Loss" non scende per 3 epoche consecutive, il sistema riduce il Learning Rate (factor=0.5) per affinare la precisione.

L'ultimo livello della rete (Fully Connected) è stato sostituito con un neurone singolo (`nn.Linear(num_ftrs, 1)`) seguito da una funzione di attivazione **Sigmoide** (`nn.Sigmoid`), ideale per output binari (0 = Sano, 1 = Disgrafico).

Preprocessing e Adattamento dell'Input

Data Augmentation (Arricchimento Dati)

Training con Cross-Validation e Scheduler

Classificazione Binaria

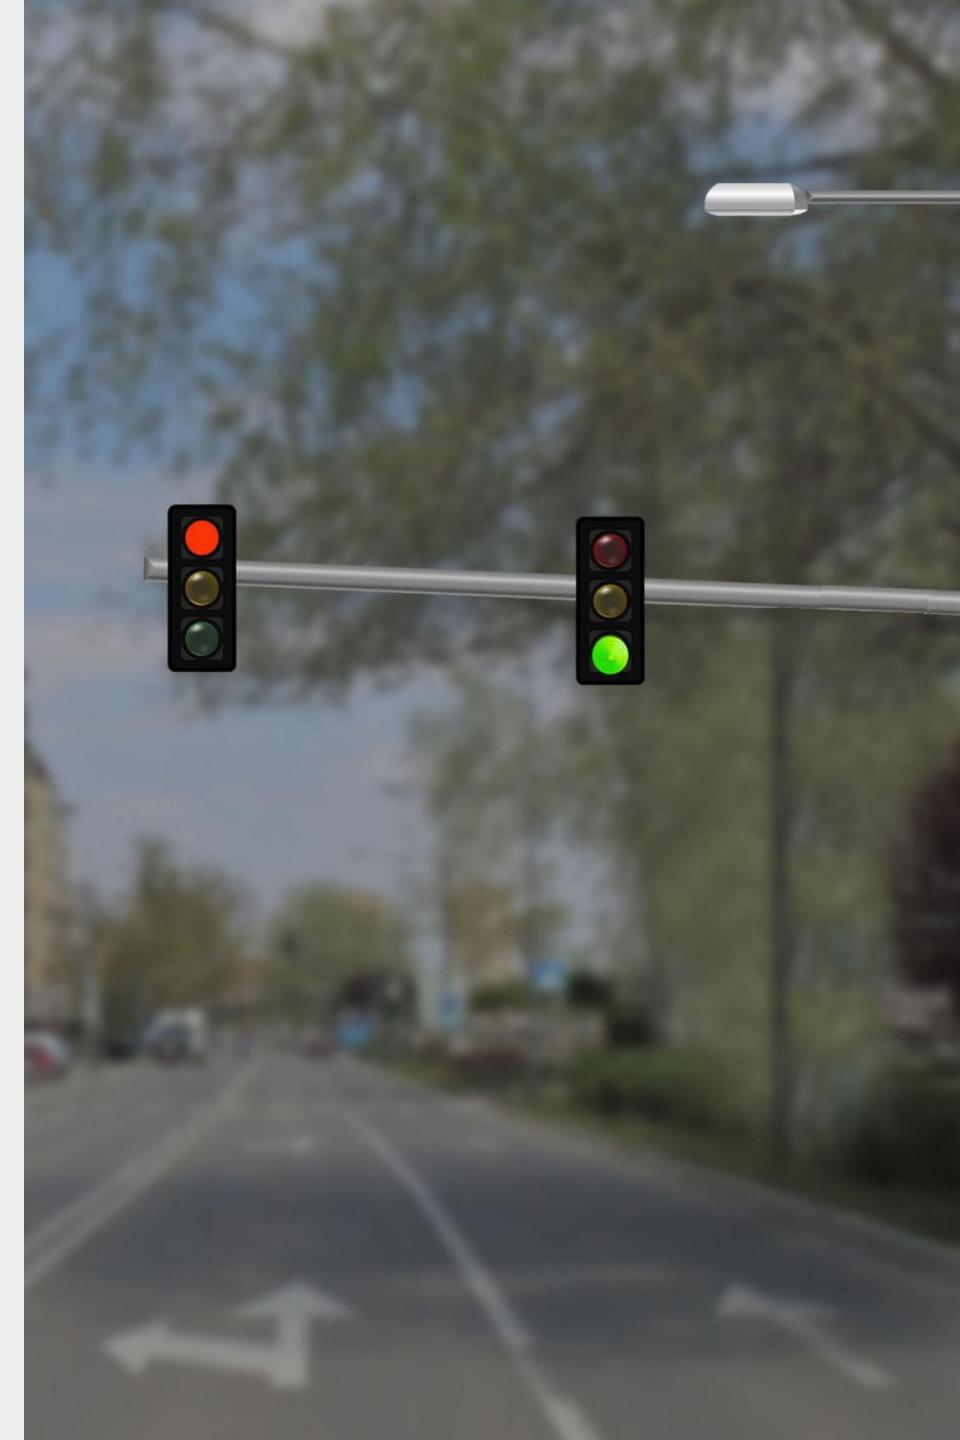
Output

Il codice produce a terminale un output immediato caratterizzato da indicatori di rischio per ogni foto analizzata nello screening.

IMG_1249.png
CNN: ● Approfondimento (1.00)
SVM: ● Approfondimento (0.98)

p1_L8.png
CNN: ● Nella norma (0.32)
SVM: ● Approfondimento (0.99)

p1_L9.png
CNN: ● Monitoraggio (0.42)
SVM: ● Approfondimento (0.99)



Limiti del codice

1. Il Limite "Clinico": Cecità Dinamica

- **Il Limite:** La disgrafia non è solo "come appare" la scritta, ma "come è stata fatta". La rete vede solo il risultato finale (l'inchiostro sul foglio).
- **Cosa perde:** la **pressione** della penna, la **velocità** del tratto, le esitazioni o l'ordine con cui sono stati fatti i segni.
- **Conseguenza:** Potrebbe confondere una scrittura brutta (ma fluida) con una scrittura disgrafica (lenta e tremolante), perché guarda solo i pixel finali.

Possibile soluzione

Uso tablet e/o penna sensoriale

2. Il Limite del "Domain Gap" (Gap di Dominio)

- **Il Limite:** ImageNet contiene foto di cani, gatti, auto, paesaggi. Non contiene calligrafia.
- **Cosa succede:** Deve fare uno sforzo notevole (Fine-Tuning) per dimenticare quelle forme e imparare a riconoscere i tratti delle lettere
- **Conseguenza:** Sebbene funzioni bene (90% di accuracy), una rete pre-addestrata specificamente su caratteri (come il dataset EMNIST) potrebbe essere ancora più efficiente o veloce.

Possibile soluzione

Dataset di scrittura a mano
(es. EMINST, IAM
Handwriting Dataset)

Limiti del codice

3. Il Limite della Risoluzione

- **Il Limite:** Riducendo a 128x128 per velocizzare il calcolo, perdi informazioni.
- **Cosa perde:** Un leggero **tremore** della mano (micro-grafia), che è un segno clinico importante della disgrafia, potrebbe sparire o sembrare solo una sfocatura quando l'immagine viene rimpicciolita a 128 pixel.

Possibile soluzione

Dividere il campione in tanti piccoli campioni

4. Il Limite della "Black Box" (Spiegabilità)

- **Il Limite:** Se la ResNet dice "Disgrafico al 95%", non ti sa dire **perché**.
- **Confronto:** L'SVM (il modello vecchio) usa feature che capiamo: "Densità inchiostro". Se l'SVM sbaglia, possiamo dire "ha sbagliato perché c'era troppo inchiostro".
- **Conseguenza:** La ResNet è una "scatola nera". Non sappiamo se ha classificato il bambino come disgrafico perché ha visto una "a" storta o semplicemente perché la foto era un po' più scura.

Possibile soluzione

Grad-CAM

CONFRONTO MODELLI E OUTPUT

- MODELLI UTILIZZATI
- PERFORMANCE E VISUALIZZAZIONI
- APPLICAZIONI SCOLASTICHE

Modelli utilizzati

Il Modello Principale: ResNet18 (Deep Learning)

Rete Neurale Convoluzionale (CNN) profonda 18 strati.

Tecnica usata: Transfer Learning. Invece di partire da zero, il codice scarica i pesi preaddestrati. Questo modello **apprende rapidamente** e raggiunge un'accuratezza elevata (~90% in validazione).



Il Modello di Confronto: Support Vector Machine (Machine Learning Classico)

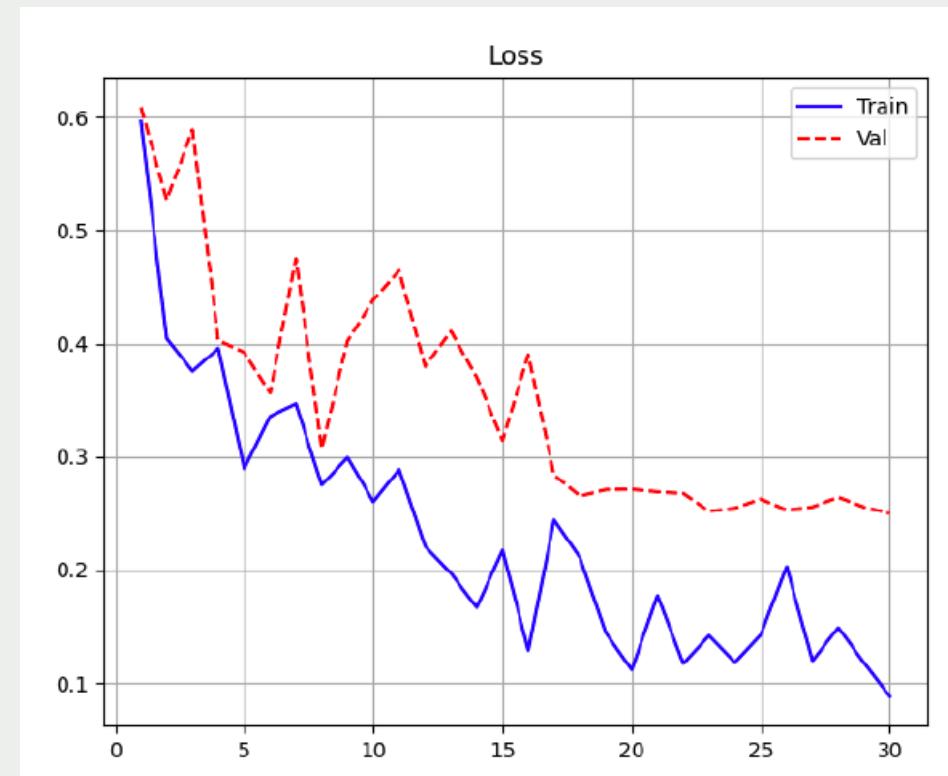
A differenza della ResNet, l'SVM non guarda l'immagine grezza. Il codice estrae manualmente due caratteristiche matematiche prima di passargliele: Istogramma: La distribuzione dei toni di grigio; Densità: La quantità di pixel neri rispetto al bianco

Risultati: Come mostra il boxplot l'SVM si ferma al 55% di accuratezza, dimostrandosi **inefficace** rispetto alla ResNet.

Performance e visualizzazioni - Loss

Andamento della loss in ResNet18 (CNN)

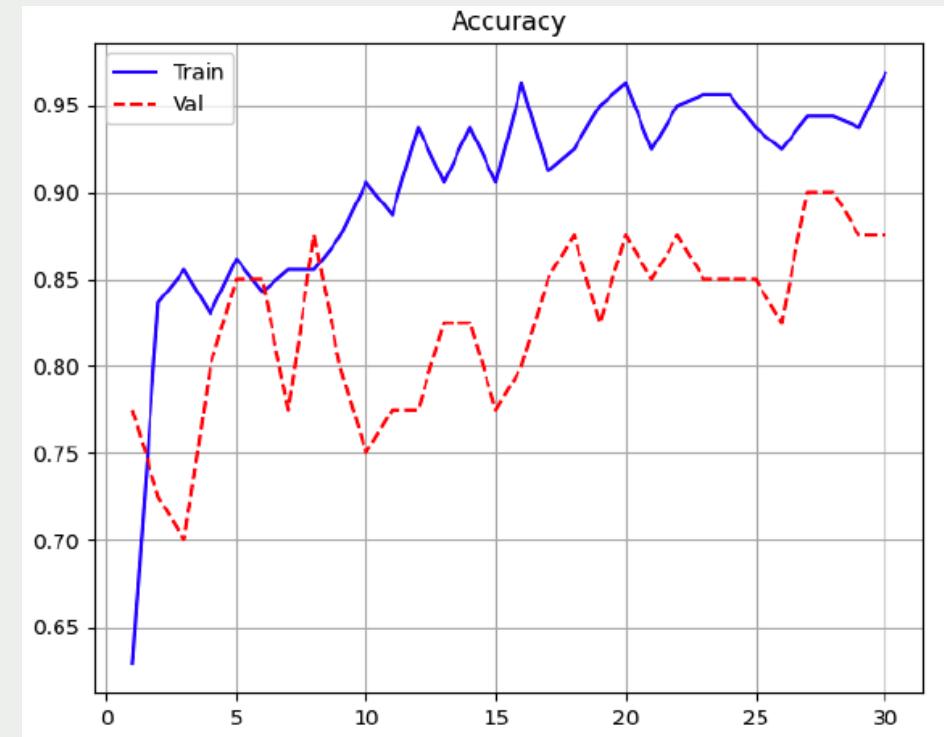
- Discesa Ripida: entrambe le linee (Blu e Rossa) crollano rapidamente all'inizio. Significa che il modello ResNet ha imparato quasi subito a distinguere le due categorie.
- Il Gap (Lo Spazio tra le linee): la linea Blu (Training) continua a scendere quasi a zero, mentre la linea Rossa (Validation) si ferma più in alto (intorno a 0.25) significa che il modello sta diventando "perfetto nel Training, ma mantiene comunque un errore basso e costante nella Validation.



Performance e visualizzazioni - Accuracy

ACCURACY (La Precisione)

- Picco del 90% (linea rossa)
- Il "Zig-Zag" della linea rossa: dipende dal dataset di test piccolo. Basta che il modello sbagli una sola immagine in più o in meno per far saltare la linea su o giù del 2-3%. È un comportamento fisiologico con pochi dati.



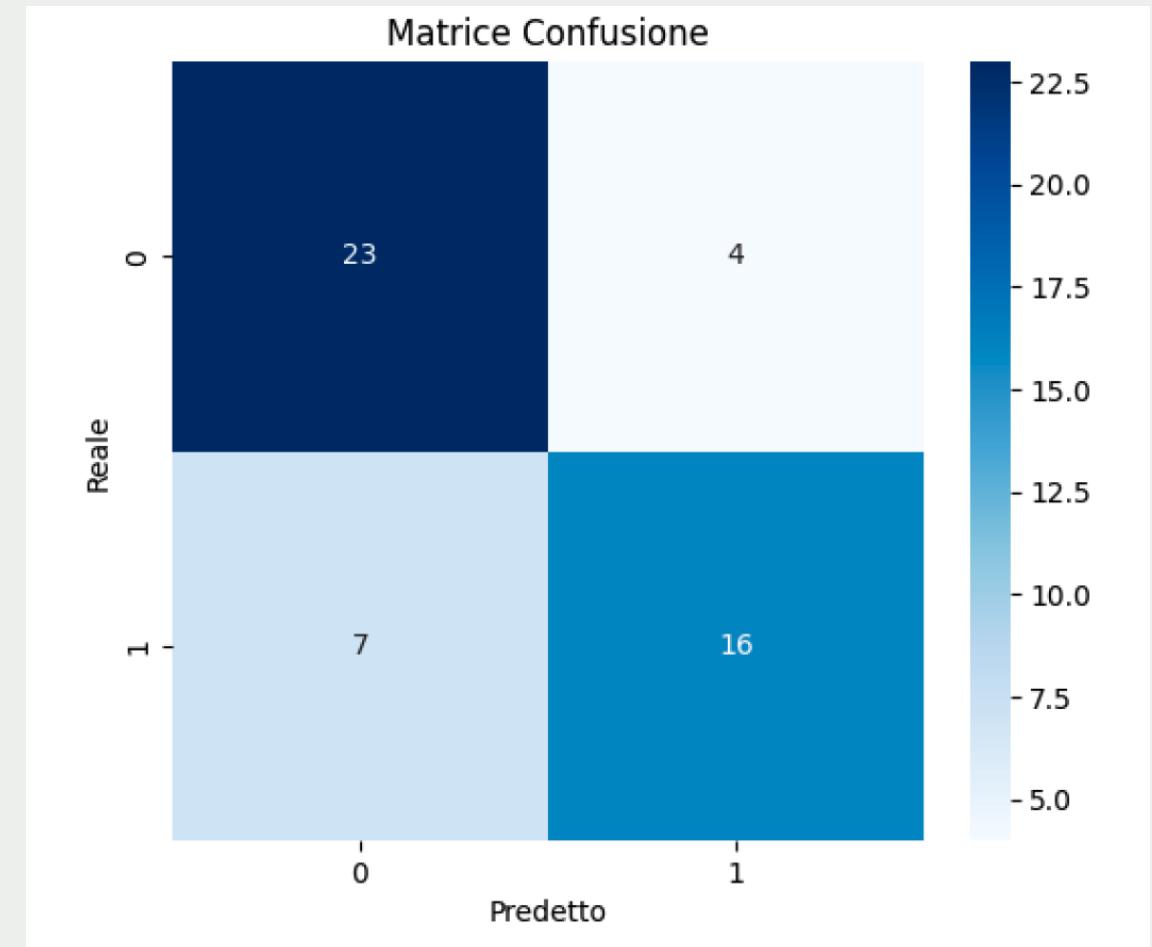
Performance e visualizzazioni – Matrice di confusione

- Totale Immagini: 50
- Indovinate (Diagonale Blu Scuro): $23 + 16 = 39$
- Sbagliate (Diagonale Azzurra): $4 + 7 = 11$
- Accuratezza Finale sul Test: $39 / 50 = 78\%$

Analisi degli errori:

- Sani (Classe 0): Ne ha indovinati 23 su 27. (Solo 4 falsi allarmi).
- Disgrafici (Classe 1): Ne ha indovinati 16 su 23.

Ci sono 7 Falsi Negativi (il numero in basso a sinistra). Significa che 7 bambini disgrafici sono stati classificati come "Sani".



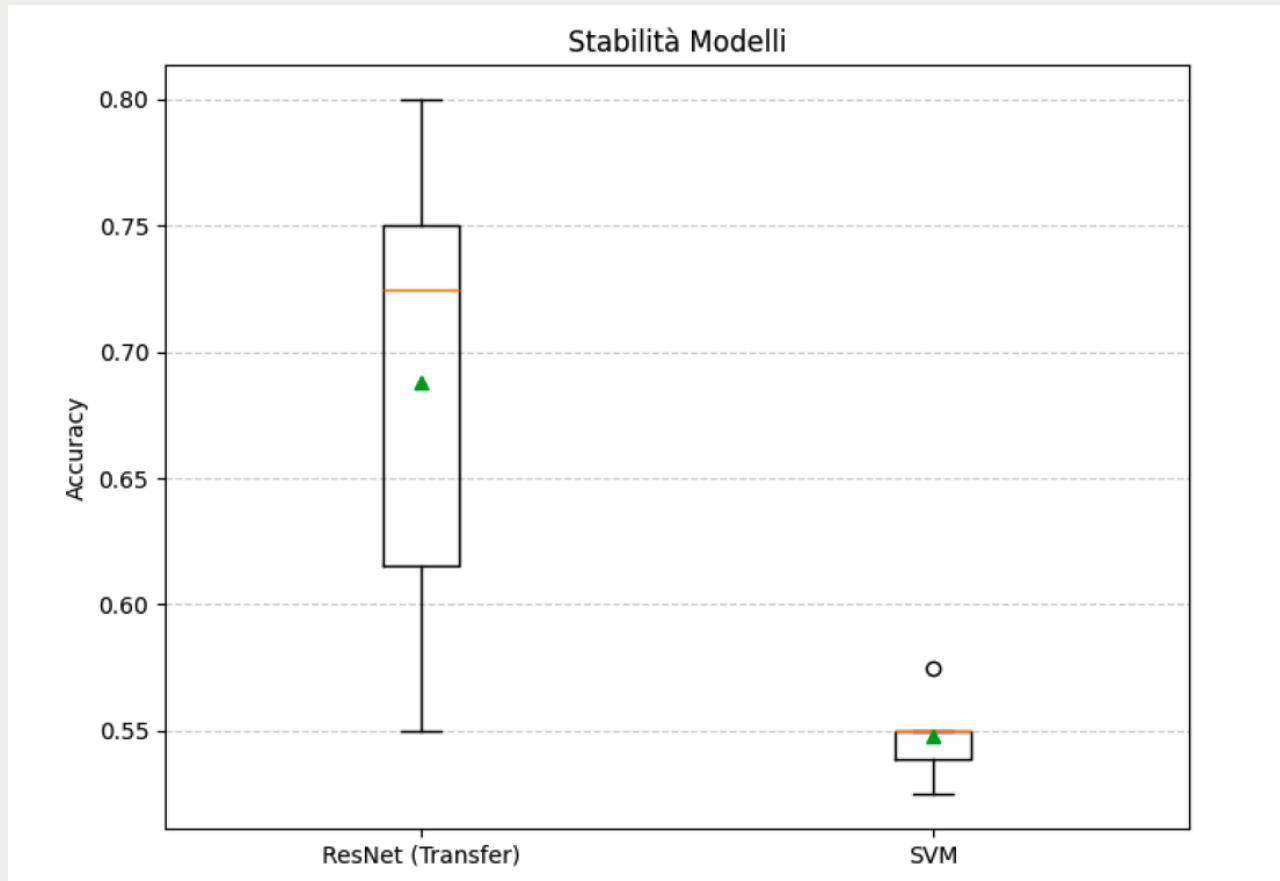
Performance e visualizzazioni - Boxplot

ResNet (A Sinistra):

La scatola è molto più in alto
(media intorno al 70-73%).

Qui l'accuracy è 70 e non
90 perché questo grafico è
stato generato dalla Cross-
Validation, che nel codice fa un
"test rapido" di sole 3 epocha
per ogni giro.

Boxplot: confronto tra i modelli



SVM (A Destra): La
scatola è bassissima,
schiacciata intorno al
0.55 (55%).

Essendoci due classi
(Sano/Disgrafico), fare il
50% significa
letteralmente tirare a
indovinare.

CONCLUSIONI E PROSPETTIVE

- COSA ABBIAMO RAGGIUNTO
- COME MIGLIORARE ANCORA
- FONTI

Cosa abbiamo raggiunto

Il progetto ha dimostrato la fattibilità tecnica di uno strumento di screening automatico per la disgrafia, ottenendo risultati promettenti nonostante la limitata disponibilità di dati clinici.

- **Superiorità del Deep Learning:** Il confronto sperimentale ha evidenziato che l'approccio basato su **ResNet18 e Transfer Learning** è nettamente superiore ai metodi classici. Il modello Deep Learning ha raggiunto un'accuratezza in validazione vicina al **90%**, mentre l'SVM (Support Vector Machine) si è fermato al **55%**, dimostrandosi incapace di gestire la complessità e la variabilità della scrittura infantile solo tramite feature manuali (densità e istogrammi).
- **Efficacia del Transfer Learning:** Abbiamo superato il problema della scarsità di dati (pochi campioni di bambini disgrafici) sfruttando una rete pre-addestrata su ImageNet. Questo ha permesso al modello di "sapere già come vedere", riducendo drasticamente i tempi di addestramento e il rischio di overfitting.
- **Ruolo nello Screening Scolastico:** Lo strumento sviluppato risponde all'esigenza di metodi rapidi e oggettivi per la scuola primaria. Non si sostituisce alla diagnosi specialistica (multidisciplinare), ma agisce come un "campanello d'allarme" precoce per individuare i soggetti a rischio e indirizzarli tempestivamente ai clinici, riducendo i tempi di attesa e la soggettività dell'osservazione umana.

Come migliorare ancora

Dall'Analisi Statica all'Analisi Dinamica:

- Implementare l'acquisizione tramite **tablet e penne digitali**, utilizzando reti neurali ricorrenti (RNN/LSTM) per analizzare la sequenza temporale del gesto grafico.

Spiegabilità (Explainable):

- Generare "mappe di calore" che evidenziano visivamente sull'immagine quali lettere o tratti hanno determinato la classificazione di "rischio disgrafia".

Miglioramento della Risoluzione:

- Adottare un approccio **Patch-based**, analizzando il foglio ad alta risoluzione pezzo per pezzo invece di comprimerlo tutto in una piccola immagine.

Applicazione Mobile per Insegnanti:

- Trasformare il codice Python attuale in una **Web App o App Mobile** facile da usare. L'App permetterebbe agli insegnanti di fotografare il quaderno e ricevere un feedback immediato (Semaforo Verde/Giallo/Rosso), garantendo al contempo l'anonimato dei dati per rispettare la privacy degli studenti.

Fonti

Progetto realizzato con il supporto di

Article:

Automated systems for diagnosis of dysgraphia in children: a survey and novel framework

Dataset:

ResNet18

Potential Dysgraphia Handwriting Dataset (Mendeley Data) - licenza CC BY 4.0